

Evaluating Large Language Models for Software Testing

Gustavo Santiago <gssm> João Teles <jant> Rafael Leite<rlo3>

Introdução

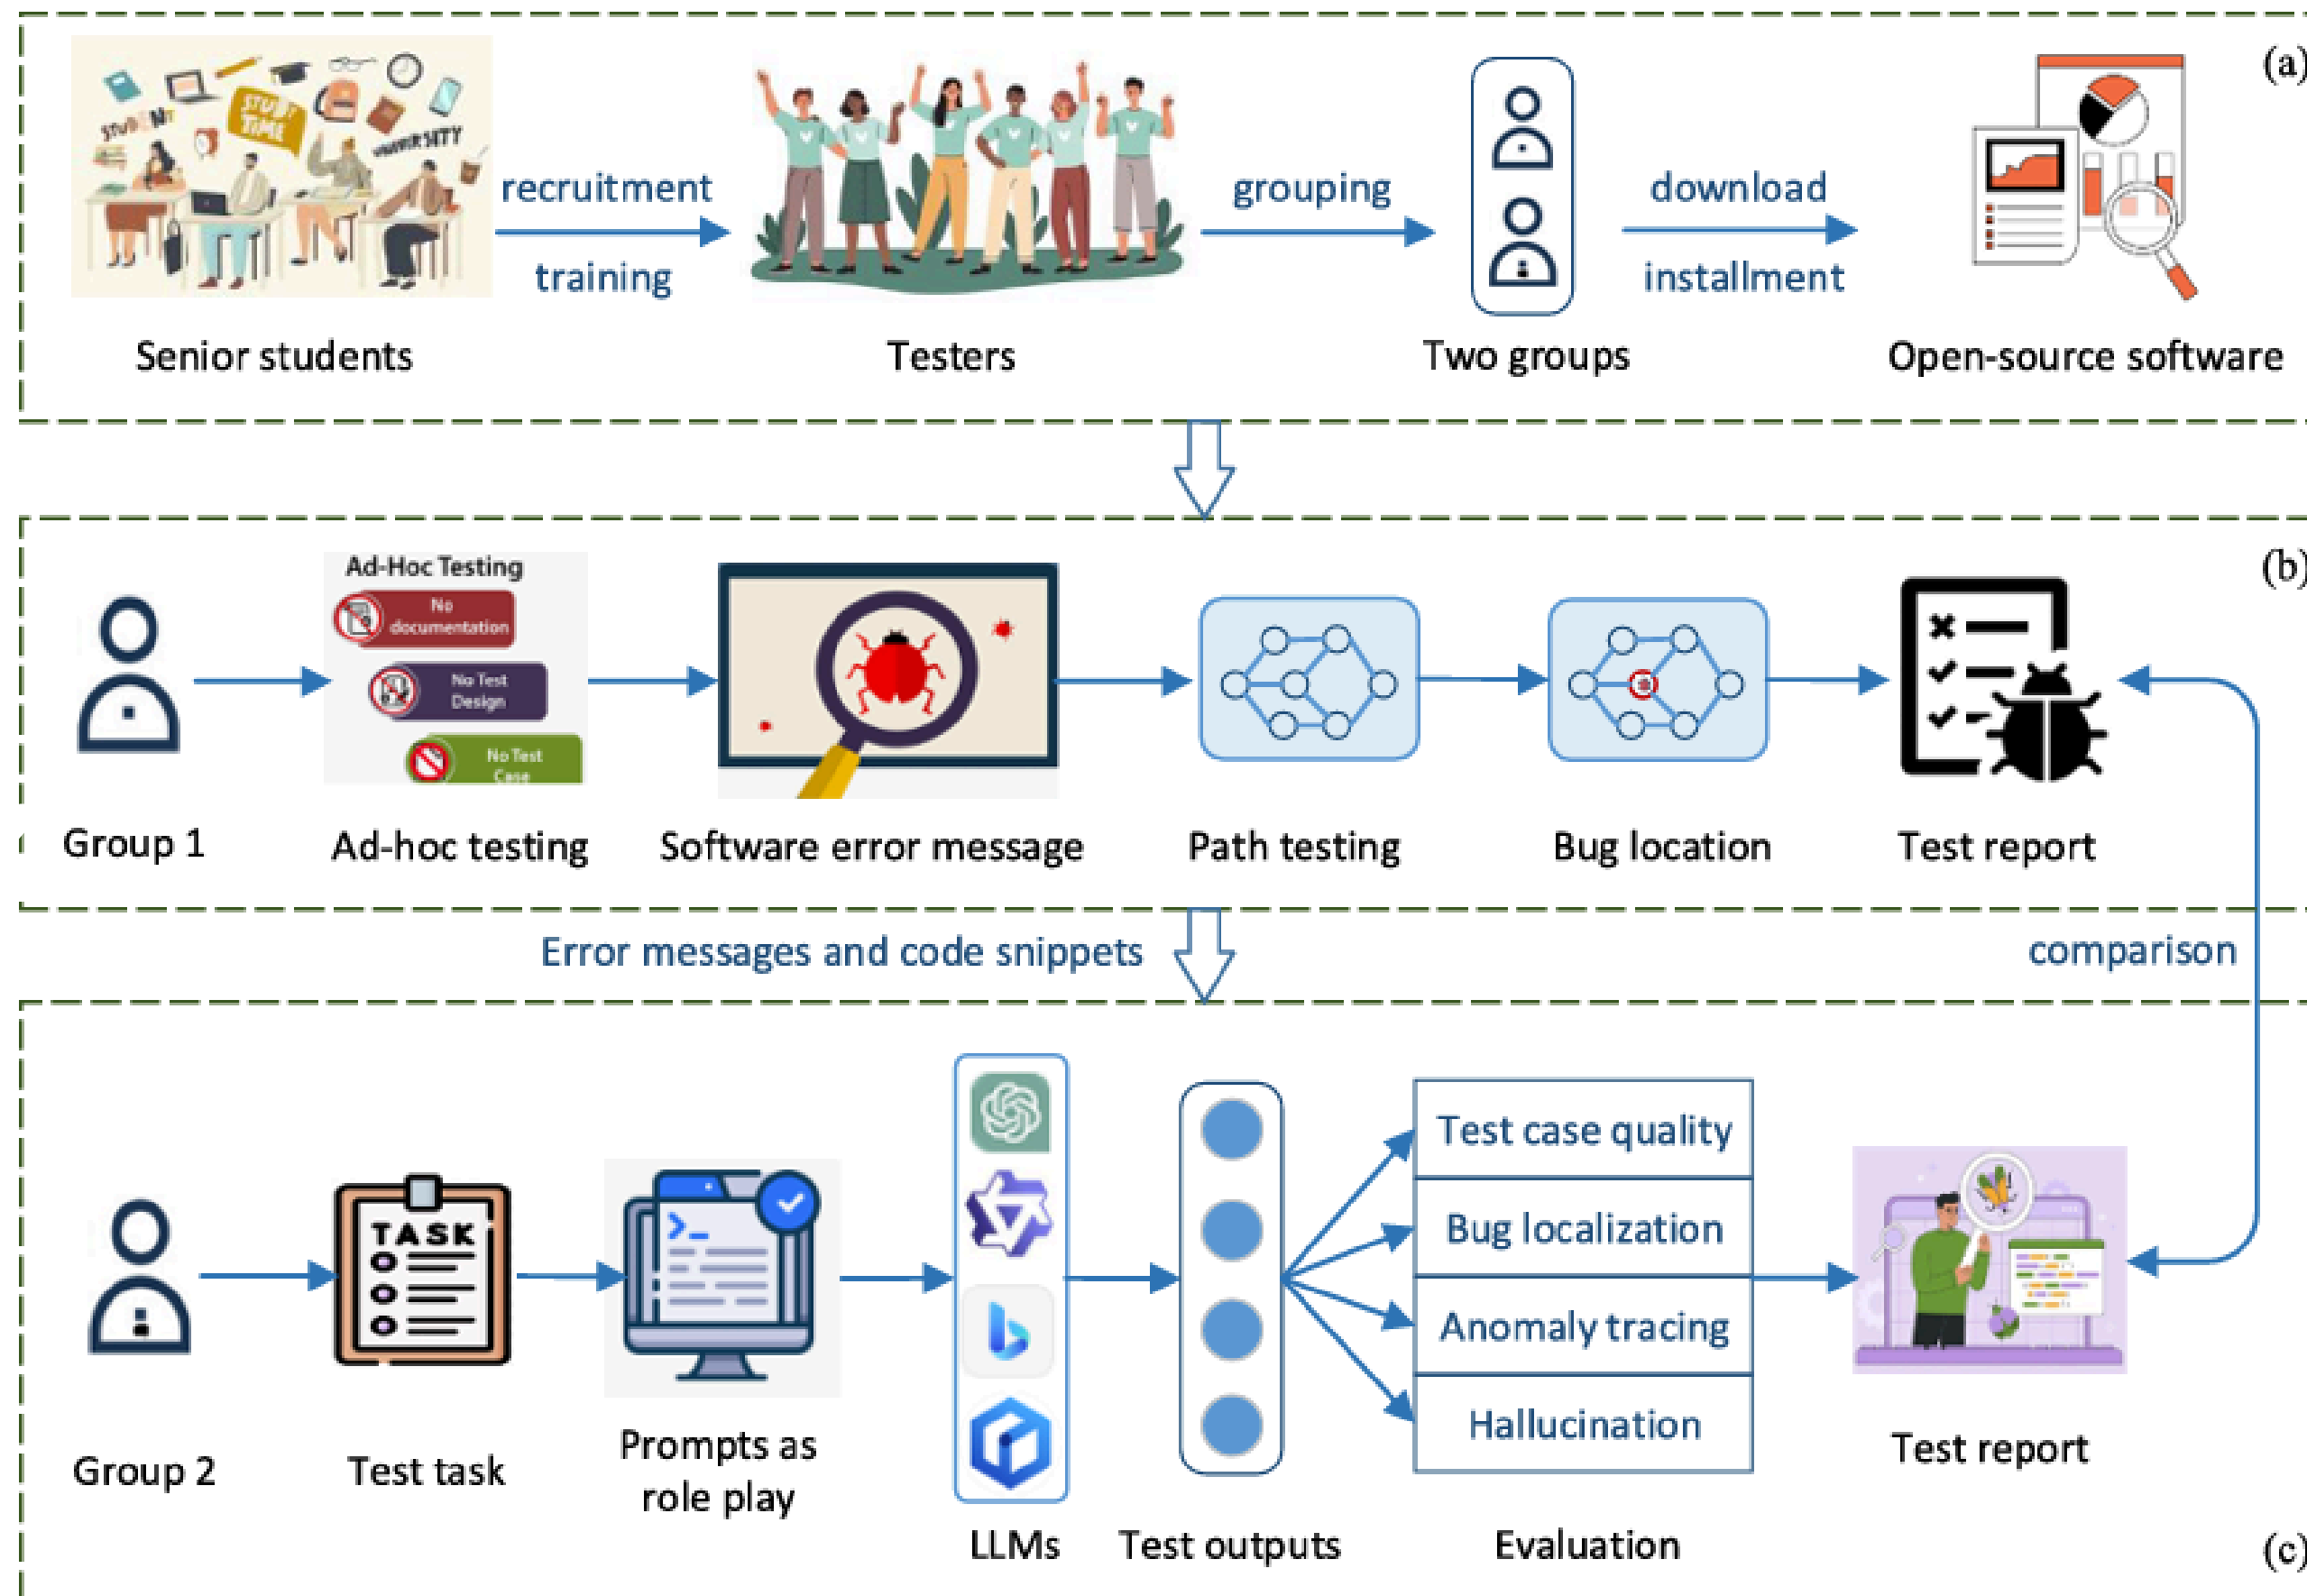
Motivação

Introdução

O artigo propõe:

1. **Novo framework de avaliação:** Comparar LLMs com testes manuais para medir capacidades reais de generalização
2. **Uso de softwares open-source:** Garantir reprodutibilidade e simular erros de aplicações reais.
3. **Avaliação em múltiplas dimensões:** Test case generation, bug localization, error tracing e análise de hallucinations.
4. **Método de follow-up question:** Reforçar a detecção de bugs ao solicitar verificações adicionais dos LLMs.

Framework



Cenário do Experimento

- 48 estudantes seniores de computação com experiência em desenvolvimento.
- Divididos aleatoriamente em Grupo Manual e Grupo LLM.
- 12 projetos Open-Source (não sintéticos) para garantir que simulam o mundo real.

Softwares Open-Source Usados

- **MySQL** → Um sistema de gerenciamento de banco de dados relacional.
- **Jenkins** → Uma ferramenta de integração contínua baseada em Java.
- **Node.js** → Um ambiente de execução JavaScript baseado no motor V8 do Chrome.
- **FreeCAD** → Uma ferramenta open-source de CAD/CAE baseada no OpenCASCADE.
- **Jmeter** → Uma poderosa ferramenta open-source de teste de desempenho.
- **Eclipse** → Uma plataforma de desenvolvimento extensível baseada em Java e open-source.
- **PuTTY** → Um software de conexão de interface serial, comumente usado para controle de login remoto.
- **NetBeans** → Um ambiente de desenvolvimento integrado open-source para a linguagem Java.
- **Cmder** → Uma ferramenta de linha de comando aprimorada e amigável ao usuário.
- **7-zip** → Um software gratuito e open-source de compressão/descompressão de arquivos.
- **VirtualBox** → Um poderoso software de máquina virtual x86.
- **MariaDB Connector/Python** → Um conector de banco de dados open-source para Python.

O Escopo da Avaliação

- **Geração de Casos de Teste:** Criar passos para testar funcionalidades específicas .
- **Rastreamento de Erro (Error Tracing):** Analisar uma mensagem de log e dizer a causa.
- **Localização de Bug:** Analisar um snippet de código e apontar a linha do defeito .

Padronização dos Prompts

Prompt: "Atue como um testador de software profissional e complete a seguinte tarefa: [Tarefa de Teste]"

Foi usado Role-Playing

- O prompt foi fixo para garantir consistência entre os 6 modelos avaliados.

Como definimos "Sucesso"?

- O grupo de Teste Manual serviu como "Gabarito" (Benchmark).
- Se a IA achou um bug que o humano achou = Sucesso.
- Se a IA achou um bug que o humano NÃO achou = Sucesso Extra.
- Se a IA inventou um bug (não executável) = Alucinação (Ponto chave para a apresentação).

Lista de Mensagens de Erro

Table 2
Error messages and reasons obtained from ad-hoc testing of 12 software packages under test

Software	Error Message	Source of Error
MySQL	Error 1: Initial root password fails to run. Error 2: Running the command MYSQLd –install in the cmd window results in an error message "Install/Remove of the Service Denied!".	Previous installation of MYSQL on the computer. Not using administrator privileges.
Jenkins	Error 3: Upon restarting Jenkins and then attempting to start it again, an error "Failed to start Jenkins Continues Integration Server" occurs. Error 4: Error occurs when saving project configuration information. Error 5: Integration with version control system fails to pull or push code. Error 6: Jenkins build triggers fail to trigger builds according to preset conditions.	Using an old version command for starting Jenkins with a new version installation results in failure. Incorrect configuration of project parameters by the user. Incorrect configuration information or insufficient access permissions for the version control system. Incorrect configuration of build trigger types and parameters by the user.
Node.js	Error 7: Failed to compile with 1 error. Error 8: Node.js process crashes.	Incompatibility between the Node.js version and the project. Incorrect page parameter passing leads to Node.js process crash.
FreeCAD	Error 9: Unable to connect to GitHub.	Inaccessibility of gist.github.com.
Jmeter	Error 10: Error occurs when using a template in Jmeter.	Bug in the namespacesParse(String namespaces) method of the XPathUtil class in the program package.
Eclipse	Error 11: Plugin error.	Incorrect conversion leading to failure to find plugin rule.
PutTY	Error 12: Window problem during secondary connection. Error 13: Window size setting issue.	Design flaw in the code. Design flaw in the code.
NetBeans	Error 14: Failure to add Cloud.	Bug in the camelize function of the Inflector class.
Cmder	Error 15: CSV text display issue related to the invoked ConEmu terminal emulator. Error 16: Exception during character copying.	Related to the invoked ConEmu terminal emulator. Related to the invoked ConEmu terminal emulator.
Virtualbox	Error 17: Virtualbox suddenly fails to run after multiple restarts over several days.	The settings of the firewall are changed.
Mariadb-Connector-Python	Error 18: Failure in query function testing. Error 19: Failure in transaction function testing due to attempting to insert data into a non-existent table, causing the transaction to fail. Error 20: Compatibility testing failure.	Executing a query on a non-existent table in the test case. Attempting to insert data into a non-existent table during the transaction test. Lack of support for Python 2.x versions.
7-zip	Error 21: Failure in 'test_error_message_readability' test case. Error 22: Lack of prompt messages upon clicking the Information button without selecting a file. Error 23: Lack of prompt messages upon clicking the Delete button in the toolbar without selecting a file. Error 24: Inability to copy files in the same path after selection. Error 25: No length limit on password input during file compression encryption.	Bug in the error output code. Issue with the button code. Issue with the button code. Error in the file copying code. Lack of length check in the encryption input box of the compression window.

Table 3
Summary of information on 6 LLMs under evaluation

No	LLM	Versions	Max Token	Company	Website
1	GPT-4	4	32000	OpenAI	https://chat.openai.com/
2	GPT-3.5	3.5	4096	OpenAI	https://chat.openai.com/
3	ERNIE Bot	4	5000	Baidu	https://yiyan.baidu.com/
4	Doubao	Unavailable	3000	Tiktok	https://www.doubao.com/chat/
5	New Bing	4	8000	Microsoft	https://www.bing.com/chat
6	SparkDesk	3	5403	Iflytek Co. Ltd	https://xinghuo.xfyun.cn/

Modelos Usados

Respondendo As RQs

RQ1: How is the quality of test cases generated by LLMs?

RQ2: How well can LLMs identify the cause of software errors from messages?

RQ3: How effective is the bug localization capability of LLMs?

RQ4: Do LLMs experience hallucination issues during software testing

RQ1: Métricas Usadas

Sigla	Descrição Simplificada	Fórmula
TER	Razão de testes gerados pelo LLM que executam	$TER = \frac{N_{exe}}{N_{all}}$
BDR	Razão de bugs identificados manulamente que também foram identificados pelo LLM	$BDR = \frac{ A \cap B }{ B }$
ABDCR	Razão de bugs identificados pelo LLM que não foram identificados manualmente	$ABDCR = \frac{ A - B }{ A }$
QTC	Média ponderada entre TER, BDR e ABDCR	$QTC = \frac{1}{n} \sum_{i=1}^n (0.2 \times TER_i + 0.4 \times BDR_i + 0.4 \times ABDCR_i)$

RQ1: Qualidade dos casos de testes

Table 4
The evaluation of test cases generated by six LLMs

LLMs	7-zip			Jenkins			Node.js		
	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>
GPT-3.5	100%	0%	0%	100%	0%	0%	100%	0%	0%
ERNIE Bot	100%	0%	100%	100%	50%	0%	100%	50%	50%
New Bing	57%	0%	0%	100%	0%	0%	0%	0%	0%
GPT-4	100%	0%	0%	100%	25%	0%	100%	0%	0%
Doubao	93%	0%	100%	100%	0%	0%	95%	50%	0%
SparkDesk	100%	0%	0%	100%	75%	0%	88%	0%	0%
LLMs	FreeCAD			Jmeter			Eclipse		
	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>
GPT-3.5	100%	0%	100%	100%	0%	0%	100%	100%	50%
ERNIE Bot	100%	0%	0%	100%	0%	0%	100%	100%	75%
New Bing	0%	0%	0%	0%	0%	0%	0%	0%	0%
GPT-4	100%	0%	0%	100%	0%	0%	100%	100%	50%
Doubao	100%	100%	0%	100%	0%	0%	100%	100%	75%
SparkDesk	100%	100%	0%	83%	0%	0%	83%	0%	0%
LLMs	PuTTY			NetBeans			Cmder		
	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>
GPT-3.5	100%	0%	0%	100%	0%	0%	100%	0%	0%
ERNIE Bot	100%	100%	0%	100%	0%	0%	100%	50%	0%
New Bing	0%	0%	0%	0%	0%	0%	0%	0%	0%
GPT-4	100%	0%	0%	100%	0%	0%	100%	0%	0%
Doubao	100%	0%	0%	100%	0%	0%	100%	0%	0%
SparkDesk	100%	0%	100%	100%	0%	100%	100%	0%	0%
LLMs	Virtualbox			Mariadb-Connector-Python			MySQL		
	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>	<i>TER</i>	<i>BDR</i>	<i>ABDCR</i>
GPT-3.5	100%	0%	0%	100%	25%	0%	100%	0%	0%
ERNIE Bot	100%	0%	0%	100%	25%	0%	100%	0%	0%
New Bing	0%	0%	0%	100%	0%	0%	0%	0%	0%
GPT-4	100%	0%	0%	100%	50%	0%	100%	0%	0%
Doubao	100%	0%	0%	93%	25%	0%	100%	0%	0%
SparkDesk	100%	0%	0%	100%	0%	0%	80%	0%	0%

RQ1: Qualidade dos casos de testes




Fig. 2. Quality of test cases (QTC) generated by the six large language models

Table 5
The frequency with which each LLM falls into the four scenarios across 12 software packages

Scenario	GPT-3.5	ERNIE Bot	New Bing	GPT-4	Doubao	SparkDesk
1.BDR>0% and ABDCR=0%	1/12	4/12	0/12	2/12	3/12	2/12
2.BDR>0% and ABDCR>0%	1/12	2/12	0/12	1/12	1/12	0/12
3.BDR=0% and ABDCR=0%	9/12	5/12	12/12	9/12	7/12	8/12
4.BDR=0% and ABDCR>0%	1/12	1/12	0/12	0/12	1/12	2/12

RQ2: Métricas Usadas

Sigla	Descrição Simplificada	Fórmula
EOR	Porcentagem de acertos (entre 0 e 1)	$EOR = \frac{1}{m} \sum_{i=1}^m f(X_i)$
OAR	Recompensa respostas concisas (com menos itens)	$OAR = \frac{\sum_{i=1}^m f(X_i)}{\sum_{i=1}^m \#X_i}$
ETC	Recompensa respostas que acham o erro mais cedo (itens com menores índices)	$ETC = \sum_{i=1}^m (f(X_i) + g(X_i))$

$$f(X) = \begin{cases} 1 & \text{exist an effective ouput item in } X \\ 0 & \text{otherwise} \end{cases}$$

$$g(X_i) = \begin{cases} \frac{0.1}{i} & f(X_i) = 1 \\ 0 & f(X_i) = 0 \end{cases}$$

RQ2: Rastreamento de erros

Table 6
Performance of six LLMs in identifying the sources of software errors

Software and errors		GPT-3.5	ERNIE Bot	Doubao	New Bing	SparkDesk	GPT-4
MySQL	Error 1	5/5	1/4	-/3	-/2	-/4	5/5
	Error 2	1/2	1/7	1/2	1/3	2/3	1/3
Jenkins	Error 3	3/6	1/3	-/4	1/4	-/4	6/6
	Error 4	1/3	1/3	1/1	2/4	1/3	1/5
	Error 5	2/7	2/7	2/4	2/5	1/7	2/6
	Error 6	1/7	1/6	1/4	3/5	1/6	1/6
Node.js	Error 7	2/4	1/5	1/1	5/7	5/5	2/5
	Error 8	1/1	1/1	1/1	1/4	1/1	1/3
FreeCAD	Error 9	1/5	1/4	1/3	1/4	1/8	1/5
Jmeter	Error 10	-/5	1/4	1/4	-/2	1/4	-/5
Eclipse	Error 11	1/5	1/6	1/3	1/5	2/4	2/5
PuTTY	Error 12	-/3	-/3	-/2	-/1	-/5	-/4
	Error 13	-/3	1/3	-/3	-/3	2/5	1/4
NetBeans	Error 14	-/4	-/6	-/4	-/4	-/5	-/6
Cmder	Error 15	1/1	1/1	1/1	-/2	1/1	-/4
	Error 16	-/1	1/8	-/3	-/3	-/1	-/3
Virtualbox	Error 17	2/5	2/7	-/3	-/3	-/14	2/7
Connector-Python	Error 18	2/5	3/6	-/5	3/4	2/5	1/4
	Error 19	2/5	2/5	3/3	1/4	2/5	1/4
	Error 20	1/3	1/3	1/1	1/2	1/2	1/2
	Error 21	1/3	1/4	-/3	-/4	5/5	3/4
7-zip	Error 22	5/5	1/1	2/2	-/3	2/3	1/1
	Error 23	5/5	1/1	2/2	-/3	2/3	1/1
	Error 24	-/6	-/5	4/4	-/4	5/5	-/3
	Error 25	2/4	-/4	2/2	-/4	3/3	1/3

RQ2: Rastreamento de erros




Fig. 3. Effective output ratios of the six LLMs




Fig. 4. Output accuracy ratios of the 6 LLMs




Fig. 5. Error tracing capabilities of the 6 LLMs

RQ3 e RQ4: Métricas Usadas

Sigla	Descrição Simplificada	Fórmula
BLC	Razão de bugs encontrados pelo LLM em relação ao de bugs encontrados manualmente	$BLC = \frac{n_{LLM}}{n_{manual}}$
BLCR	BLC relativo ao melhor modelo	$BLCR_i = \frac{BLC_i}{\max\{BLC_1, BLC_2, \dots, BLC_n\}}$
HR	Porcentagem de resultados “alucinados”	$HR = \frac{n_h}{n_b}$

RQ3: Localização de Bugs




Fig. 6. Bug localization capability ratio of six LLMs

Table 7
Comparison of LLMs and manual tests in the number of bug localization

Item	ERNIE Bot	GPT-3.5	GPT-4	SparkDesk	Doubao	New Bing	Manual path testing
FreeCAD	1	1	1	0	0	0	1
Jmeter	2	1	0	1	2	1	1
Eclipse	2	0	2	1	0	0	1
PuTTY	2	0	1	2	1	0	2
NetBeans	2	1	1	1	0	1	1
Cmder	0	0	0	0	0	0	2
MySQL	-	-	-	-	-	-	-
Jenkins	-	-	-	-	-	-	-
Node.js	-	-	-	-	-	-	-
Virtualbox	-	-	-	-	-	-	-
Connector-Python	-	-	-	-	-	-	-
7-zip	-	-	-	-	-	-	-
Total	9	3	5	5	3	2	8

RQ4: Alucinação




Fig. 7. The hallucination issues of LLMs

O Desafio da Alucinação

- O teste via LLM é estático e probabilístico, não determinístico.
- O modelo tenta "adivinhar" a resposta, podendo inventar fatos.
- Consequência: Desperdício de tempo e recursos validando erros falsos.
- Necessidade: Julgamento humano é indispensável para filtrar o resultado.


O Método

"Follow-up Question"

- Pesquisadores notaram que pedir uma revisão melhorava o resultado.
- Após a resposta inicial, perguntar: "Existem outros bugs neste código?".

É como pedir para uma criança revisar o dever de casa; ao olhar de novo, ela encontra erros que passaram despercebidos antes.

Impacto da Revisão na Detecção de Bugs



Estratégias de Mitigação

- **Abordagem Híbrida:** Usar IA para velocidade + Humano para validação e filtro de alucinações.
- **Nível de Confiança:** Implementar sistemas que avaliem a "certeza" da resposta da IA. Confiança baixa = Revisão obrigatória.
- **Iteração:** Adotar a "Pergunta de Seguimento" como padrão no fluxo de trabalho.

Táticas de Implementação

- Engenharia de Prompt: Fornecer contexto rico e instruções passo a passo melhora a qualidade do teste.
- Múltiplos Modelos: Usar diferentes LLMs simultaneamente para cobrir as fraquezas uns dos outros (Cross-referencing).
- Segmentação: Dividir códigos grandes em partes menores para evitar limites de token e perda de contexto.

Desafios e Limitações do Estudo

- Evolução Rápida dos modelos torna benchmarks saturados ou obsoletos.
- Modelos com janelas de contexto pequenas tiveram desempenho prejudicado.
- Fator Humano: Qualidade depende da habilidade de *prompting* do testador.

Veredito Final: O Papel da IA no Teste de Software

- LLMs são eficazes em complementar testes manuais e encontrar erros novos, mas não são autônomos. A alucinação é um risco constante que exige supervisão.
- A eficiência da IA não é estática. A técnica de "Pergunta de Seguimento" (Follow-up) ativa a capacidade de autocorreção do modelo, espelhando o processo iterativo de resolução de problemas humano.
- A abordagem vencedora é Híbrida: Unir o poder computacional da IA (para varrer código e gerar casos) com a expertise humana (para filtrar alucinações e fornecer contexto via prompts).